

T.C.
OSTİM TEKNİK ÜNİVERSİTESİ

Mühendislik Fakültesi
Yapay Zeka Mühendisliği Bölümü



BİLGİSAYARLA GÖRÜ DERSİ PROJE RAPORU
HOG ile Nesne Tespiti ve Sınıflandırma

Hazırlayan:

Aziz Deniz Akmermer

220212037

4. Sınıf

Tarih: 5 Aralık 2025

İçindekiler

Özet	2
1 Giriş	3
2 Metodoloji	4
2.1 HOG Algoritması İmplementasyonu (Problem 1)	4
2.1.1 Gradyan Hesaplama	4
2.1.2 Histogram Oluşturma ve Blok Normalizasyonu	4
2.2 Nesne Tespiti Mimarisi (Problem 2)	5
2.2.1 İnsan Tespiti ve NMS Entegrasyonu	5
2.2.2 Özel Nesne (Araç) Tespiti ve Sliding Window	5
2.3 Sınıflandırma ve Performans Analizi (Problem 3)	6
3 Deneysel Sonuçlar	6
3.1 Problem 1: HOG Özelliklerinin Görselleştirilmesi	6
3.2 Problem 2.1: İnsan Tespiti ve Threshold Analizi	8
3.3 Problem 2.2: Özel Nesne (Araç) Tespiti	8
3.4 Problem 3: Sınıflandırma Performans Analizi	10
4 Analiz ve Tartışma	11
4.1 Algoritma Başarımı ve Parametrelerin Etkisi	11
4.2 Nesne Tespitinde Zorluklar	11
4.3 Sınıflandırıcı Seçimi	11
5 Sonuç	11

Özet

Bu projede, bilgisayarla görü ve görüntü işleme alanlarında temel bir özellik çıkarım yöntemi olarak kabul edilen **Histogram of Oriented Gradients (HOG)** algoritması derinlemesine incelenmiş ve uygulanmıştır. Çalışma üç temel aşamadan oluşmaktadır: Algoritmanın sıfırdan implementasyonu, nesne tespiti uygulamaları ve sınıflandırma performansı analizi.

İlk aşamada, HOG algoritmasının gradyan hesaplama, histogram oluşturma ve blok normalizasyonu adımları herhangi bir hazır kütüphane fonksiyonu kullanılmadan manuel olarak kodlanmış ve görselleştirilmiştir. İkinci aşamada, insan tespiti için OpenCV kütüphanesinin hazır modelleri kullanılmış, özel nesne (araç) tespiti için ise 1000 görüntülük bir veri seti ile özgün bir **Destek Vektör Makineleri (SVM)** modeli eğitilmiştir. Tespit başarısını artırmak ve yanlış pozitifleri azaltmak amacıyla *Non-Maximum Suppression (NMS)* algoritması sisteme entegre edilmiştir.

Son aşamada, geliştirilen sistemin performansı SVM, k-NN ve Random Forest algoritmaları ile karşılaştırmalı olarak analiz edilmiştir. Deneysel sonuçlar, HOG özelliklerinin SVM ile birleştirildiğinde katı (rigid) nesnelerin tespitinde **%98.9** doğruluk oranına ulaştığını göstermiştir.

Anahtar Kelimeler: HOG, Nesne Tespiti, SVM, Bilgisayarla Görü, Görüntü İşleme.

1 Giriş

Görüntü işleme ve yapay zeka alanında, dijital görüntüler içerisindeki nesnelerin ne olduğunu anlamak (sınıflandırma) ve nerede olduğunu bulmak (tespit etme), otonom sürüş sistemlerinden akıllı güvenlik kameralarına kadar pek çok teknolojinin temelini oluşturmaktadır. Bu problemin çözümünde en kritik adım, piksellerin ham yoğunluk değerlerini kullanmak yerine, nesneyi temsil eden ayırt edici ve gürültüye dayanıklı özniteliklerin (features) çıkarılmasıdır.

2005 yılında Navneet Dalal ve Bill Triggs tarafından önerilen **Histogram of Oriented Gradients (HOG)** [1], nesnelerin yerel şekil bilgisini, o bölgedeki yoğunluk gradyanlarının (değişimlerinin) yönelim dağılımı ile karakterize eden güçlü bir yöntemdir. HOG, aydınlatma değişimlerine ve küçük geometrik bozulmalara karşı dayanıklı olması nedeniyle, özellikle insan ve araç tespiti gibi problemlerin çözümünde uzun yıllar endüstri standardı olarak kullanılmıştır.

Bu projenin temel motivasyonu, modern derin öğrenme yöntemlerinin (CNN vb.) atası sayılan bu klasik yöntemi teorik ve pratik düzeyde kavramaktır. Proje kapsamında aşağıdaki hedefler gerçekleştirilmiştir:

1. **Teorik İmplementasyon:** HOG algoritmasının matematiksel temellerinin (türev alma, açı hesabı, normalizasyon) koda dökülmesi.
2. **Nesne Tespiti Uygulamaları:**
 - Hazır modeller kullanılarak insan tespiti ve performans optimizasyonu.
 - *Sliding Window* (Kayan Pencere) yöntemi ile sıfırdan eğitilen bir araç tespit sisteminin geliştirilmesi.
3. **Bilimsel Analiz:** Elde edilen sonuçların doğruluk (accuracy), karmaşıklık matrisi (confusion matrix) ve görsel çıktılarla analiz edilmesi.

Raporun ilerleyen bölümlerinde, kullanılan metodoloji, geliştirilen kod yapısı, toplanan veri setleri ve elde edilen deneysel sonuçlar detaylı bir şekilde sunulacaktır.

2 Metodoloji

Bu çalışmada, nesne tespiti ve sınıflandırma problemlerini çözmek amacıyla literatürde kabul görmüş Histogram of Oriented Gradients (HOG) algoritması temel alınmıştır [1]. Metodoloji üç ana fazdan oluşmaktadır: Algoritmanın matematiksel temellerinin manuel implementasyonu, farklı senaryolar (insan ve araç) için tespit sistemlerinin geliştirilmesi ve makine öğrenmesi modellerinin performans analizi.

2.1 HOG Algoritması İmplementasyonu (Problem 1)

Projenin ilk aşamasında, görüntüden öznitelik vektörü çıkarım süreci herhangi bir hazır kütüphane fonksiyonu kullanılmadan, temel lineer cebir işlemleri ile gerçekleştirilmiştir. Bu süreç dört temel adımdan oluşmaktadır.

2.1.1 Gradyan Hesaplama

Görüntü üzerindeki kenar bilgisini ve yoğunluk değişimlerini yakalamak için x ve y eksenlerinde 1-D türev maskesi $[-1, 0, 1]$ uygulanmıştır. Gri seviye bir I görüntüsü için yatay (G_x) ve dikey (G_y) gradyanlar konvolüsyon işlemi ile elde edilmiştir. Her piksel (x, y) noktasındaki gradyan büyüklüğü $|G(x, y)|$ ve yönelimi $\theta(x, y)$ aşağıdaki eşitlikler ile hesaplanmıştır:

$$G_x = I * [-1, 0, 1], \quad G_y = I * [-1, 0, 1]^T \quad (1)$$

$$|G(x, y)| = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \quad (2)$$

$$\theta(x, y) = \arctan \left(\frac{G_y(x, y)}{G_x(x, y)} \right) \quad (3)$$

Yönelim değerleri, işaretli gradyan varsayımı altında 0° ile 180° aralığına normalize edilmiştir.

2.1.2 Histogram Oluşturma ve Blok Normalizasyonu

Görüntü, yerel uzaysal bilgiyi korumak amacıyla 8×8 piksellik hücelere bölünmüştür. Her hücre için, gradyan yönelimleri 9 adet ayrık aralığa (bin) ayrılarak ağırlıklı histogramlar oluşturulmuştur.

Aydınlatma değişimlerine ve gölge etkilerine karşı dayanıklılık sağlamak amacıyla, komşu hücreler 2×2 boyutunda bloklar halinde gruplandırılmış ve her blok üzerinde L2-Norm normalizasyonu uygulanmıştır. Normalize edilmiş öznitelik vektörü v aşağıdaki gibi elde edilir:

$$v_{norm} = \frac{v}{\sqrt{\|v\|_2^2 + \epsilon^2}} \quad (4)$$

Burada ϵ , sıfıra bölünme hatasını önlemek için eklenen küçük bir sabittir ($1e^{-5}$). Sonuç olarak elde edilen bloklar birleştirilerek (concatenation) görüntüyü temsil eden nihai HOG öznitelik vektörü oluşturulmuştur.

2.2 Nesne Tespiti Mimarisi (Problem 2)

Nesne tespiti aşamasında, hem önceden eğitilmiş modeller hem de özgün veri setleri ile eğitilen denetimli öğrenme algoritmaları kullanılmıştır.

2.2.1 İnsan Tespiti ve NMS Entegrasyonu

İnsan tespiti için OpenCV kütüphanesinin INRIA veri seti üzerinde eğitilmiş HOG tanımlayıcısı kullanılmıştır. Tespit başarımını artırmak için görüntü piramidi (Image Pyramid) yöntemiyle çok ölçekli tarama (Multi-scale Detection) uygulanmıştır.

Ham tespit çıktıları genellikle aynı nesne üzerinde çok sayıda örtüşen sınırlayıcı kutu üretmektedir. Bu problemi gidermek için sisteme **Non-Maximum Suppression (NMS)** algoritması entegre edilmiştir. NMS, örtüşme oranı (Intersection over Union - IoU) belirli bir eşik değerini ($T = 0.65$) aşan kutular arasından sadece güven skoru (confidence score) en yüksek olanı korumaktadır:

$$IoU = \frac{\text{Alan}(A \cap B)}{\text{Alan}(A \cup B)} \quad (5)$$

2.2.2 Özel Nesne (Araç) Tespiti ve Sliding Window

Araç tespiti problemi için özelleştirilmiş bir tespit sistemi geliştirilmiştir. Sistem şu bileşenlerden oluşmaktadır:

- **Veri Hazırlığı:** Modelin genelleme yeteneğini artırmak için 500 pozitif (araç) ve 500 negatif (arka plan) görüntüden oluşan dengeli bir veri seti kullanılmıştır.
- **Model Eğitimi:** Çıkarılan HOG öznitelik vektörleri üzerinde bir **Linear SVM** (Support Vector Machine) sınıflandırıcısı eğitilmiştir. SVM, veriyi en iyi ayıran hiperdüzlemi şu optimizasyon problemi ile bulur:

$$f(x) = w^T x + b \quad (6)$$

- **Sliding Window Tekniği:** Test görüntüleri üzerinde 64×64 boyutundaki pencereleler, belirli bir adım aralığı (stride) ile kaydırılarak taranmış ve her pencere eğitilen

SVM modeline sunulmuştur. %50 güven eşiğini aşan bölgeler tespit olarak işaretlenmiştir.

2.3 Sınıflandırma ve Performans Analizi (Problem 3)

Geliştirilen modellerin sayısal başarısını ölçümlemek amacıyla veri seti %80 eğitim ve %20 test kümesi olarak ayrılmıştır. HOG öznitelikleri üzerinde Linear SVM, k-Nearest Neighbors (k-NN) ve Random Forest algoritmaları karşılaştırılmıştır. Performans değerlendirmesinde Doğruluk (Accuracy) metriği temel alınmıştır:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$


Ayrıca modelin sınıf bazlı hatalarını analiz etmek için Karmaşıklık Matrisi (Confusion Matrix) görselleştirmesi yapılmıştır.

3 DeneySEL Sonuçlar


Bu bölümde, geliştirilen HOG algoritmasının görselleştirme çıktıları, insan tespiti için farklı eşik değerlerinin (threshold) etkileri ve özel olarak eğitilen araç tespit modelinin performansı detaylı görsellerle sunulmuştur.

3.1 Problem 1: HOG Özelliklerinin Görselleştirilmesi


Manuel olarak implement edilen HOG algoritmasının farklı geometrik şekiller üzerindeki başarımı test edilmiştir. Şekil 1’te görüldüğü üzere, gradyan vektörleri nesnelerin kenar yönelimlerine dik olacak şekilde (örneğin dikey kenarda yatay gradyan) doğru bir şekilde hesaplanmıştır.




(a) Kare (4×4 detay)




(b) Daire (8×8 hücre)




(c) Üçgen (8×8 hücre)



(d) Yıldız (8×8 hücre)



(e) İnsan Silüeti




(f) Kare (4×4 detay)

Şekil 1: Temel geometrik şekiller üzerinde HOG algoritmasının görselleştirilmesi.

3.2 Problem 2.1: İnsan Tespiti ve Threshold Analizi

Farklı eşik değerlerinin (threshold) insan tespiti üzerindeki etkisi Şekil 2’te gösterilmiştir. Düşük eşik değerlerinde (0.1) yanlış pozitiflerin arttığı, yüksek değerlerde (0.6) ise tespit başarısının düştüğü gözlemlenmiştir.




Şekil 2: Farklı eşik değerlerinin insan tespiti üzerindeki etkisi.

3.3 Problem 2.2: Özel Nesne (Araç) Tespiti


500 pozitif ve 500 negatif görüntü ile eğitilen Linear SVM modeli, test setindeki araçları başarıyla tespit etmiştir. Şekil 3 modelin hem araç olan resimlerde (True Positive) hem de araç olmayan resimlerde (True Negative) gösterdiği performansı özetlemektedir.




(a) Başarılı Tespit 1




(b) Başarılı Tespit 2



(c) Başarılı Tespit 3



(d) Negatif Örnek



(e) Negatif Örnek



(f) Başarılı Tespit 4

Şekil 3: Özel eğitilmiş SVM modeli ile araç tespiti sonuçları.


3.4 Problem 3: Sınıflandırma Performans Analizi

HOG öznitelikleri kullanılarak eğitilen üç farklı makine öğrenmesi modelinin (Linear SVM, k-NN ve Random Forest) başarımları Tablo 1 üzerinde karşılaştırılmıştır.


Tablo 1: Sınıflandırma Algoritmalarının Performans Karşılaştırması

Algoritma	Doğruluk (Accuracy)	Hassasiyet (Precision)	Eğitim Süresi
Linear SVM	%98.99	0.99	Düşük
k-NN (k=5)	%97.98	0.98	Orta
Random Forest	%95.45	0.95	Yüksek

SVM modelinin karmaşıklık matrisi (Confusion Matrix) Şekil 4a'da verilmiştir. Modelin test setindeki 200'e yakın görüntüden sadece 2 tanesinde hata yaptığı, diğer tüm sınıfları doğru ayırdığı görülmektedir.



(a) SVM Karmaşıklık Matrisi



(b) Doğruluk Karşılaştırması

Şekil 4: Problem 3 kapsamında elde edilen sınıflandırma analizi grafikleri.

4 Analiz ve Tartışma

Bu projede elde edilen deneysel sonuçlar, HOG algoritmasının güçlü ve zayıf yönlerini ortaya koymuştur.

4.1 Algoritma Başarımı ve Parametrelerin Etkisi

Problem 1 kapsamında yapılan görselleştirmeler (Şekil 1), HOG'un nesne kenarlarını, özellikle dikey ve yatay hatları başarıyla temsil ettiğini göstermiştir. Ancak, dairesel ve karmaşık dokulu nesnelerde gradyan yönelimlerinin temsili, 8×8 hücre boyutu nedeniyle bir miktar veri kaybına uğramaktadır. Daha küçük hücre boyutu (4×4) kullanıldığında detay artmakta, ancak öznitelik vektörünün boyutu (dimensionality) 4 katına çıkarak işlem maliyetini artırmaktadır.

4.2 Nesne Tespitinde Zorluklar

İnsan tespiti deneylerinde (Şekil 2), eşik değeri (`hitThreshold`) ile tespit başarısı arasında ters orantı olduğu gözlemlenmiştir:

- Düşük eşik değerlerinde (0.1), model ağaç gövdeleri ve direkler gibi dikey yapıları insan olarak algılama eğilimindedir (False Positive).
- Yüksek eşik değerlerinde (0.6) ise modelin "katı" (rigid) yapısı nedeniyle, farklı pozlardaki veya kısmen kapanmış insanlar tespit edilememektedir (False Negative).
- **NMS'in Önemi:** Ham tespit çıktılarında bir insan üzerinde 5-6 farklı kutu oluştuğu, NMS algoritmasının bu kutuları

4.3 Sınıflandırıcı Seçimi

Problem 3 sonuçları, HOG öznitelikleri ile en uyumlu çalışan algoritmanın **Linear SVM** olduğunu kanıtlamıştır (

5 Sonuç

Bu proje kapsamında, bilgisayarla görü alanının temel taşlarından biri olan HOG algoritması literatüre uygun şekilde implement edilmiş ve gerçek hayat problemlerine uygulanmıştır.

Elde edilen bulgular şunlardır:

1. Gradyan tabanlı özniteliklerin, aydınlatma değişimlerine karşı piksel tabanlı yöntemlerden çok daha dayanıklı olduğu görülmüştür.

2. HOG + SVM ikilisinin, derin öğrenme (Deep Learning) modellerine kıyasla çok daha az veri (1000 görüntü) ve işlem gücü ile eğitilebildiği, buna rağmen
3. Geliştirilen araç tespit sisteminin, basit bir "Sliding Window" yaklaşımıyla bile otol yol görüntülerinde başarılı sonuçlar verdiği gözlemlenmiştir.

Gelecek çalışmalarda, HOG özelliklerinin renk histogramları ile birleştirilmesi veya YOLO gibi modern CNN mimarileri ile kıyaslanması hedeflenmektedir.

Kaynaklar

- [1] Dalal, N., & Triggs, B. (2005). *Histograms of Oriented Gradients for Human Detection*. IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR).
- [2] OpenCV Documentation. (2025). *HOGDescriptor Class Reference*. Eriřim Adresi: <https://docs.opencv.org/>
- [3] Scikit-image Documentation. (2025). *Histogram of Oriented Gradients*. Eriřim Adresi: <https://scikit-image.org/>
- [4] Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine learning, 20(3), 273-297.